

1ª Lista de Exercícios

PSI5123 - APRENDIZAGEM DE MÁQUINA DE SINAIS DE ÁUDIO E VOZ
(2026)

Aluno: Bruno Groper Morbin (nº USP: 11809875)

1.

Observação: todos códigos estão presentes no arquivo em anexo notebook formato .ipynb.

a)

Frequência constante: $x(t) = A \cdot \sin(2\pi 1000t)$, sendo A uma constante de amplitude.

b)

$x(t) = A \cdot \sin(2\pi 500t)$ para $t \leq 2.5s$
 $x(t) = A \cdot \sin(2\pi 1000t)$ para $t \geq 2.5s$
, sendo A uma constante de amplitude.

c)

$x(t) = A \cdot \sin(2\pi 1000t)$ para $t \leq 2s$
 $x(t) = 0$ para $t \in (2s, 3s)$
 $x(t) = A \cdot \sin(2\pi 500t)$ para $t \geq 3s$
, sendo A uma constante de amplitude.

d)

Chirp linear: frequência cresce linearmente.

Onde a função chirp é da forma:

$$x(t) = \sin(\phi(t)), \text{ com } \phi(t) = \phi_0 + 2\pi \int_0^t f(\tau) d\tau$$

E no caso do chirp linear, $f(t) = ct + f_0$, com $c = \frac{f_1 - f_0}{T} = \frac{\Delta f}{\Delta t}$

$$\Rightarrow x(t) = \sin \left[\phi_0 + 2\pi \left(\frac{c}{2} t^2 + f_0 t \right) \right] \text{ e note que } \phi_0 \text{ é a phase inicial, ou seja, quando } t = 0 \Rightarrow x(0) = \sin(\phi_0)$$

Fonte: <https://en.wikipedia.org/wiki/Chirp>

e)

Chirp exponencial: frequência cresce exponencialmente.

Neste caso, análogo ao item anterior, porém com $f(t) = f_0 \cdot k^{\frac{t}{T}}$, sendo $k = \frac{f_1}{f_0}$ e resulta em

$$x(t) = \sin \left[\phi_0 + 2\pi f_0 \left(\frac{T(k^{\frac{t}{T}} - 1)}{\ln(k)} \right) \right]$$

f)

Soma de harmônicos + ruído:


$x(t) = A_1 \sin(2\pi 450t) + A_2 \sin(2\pi 900t) + A_3 \sin(2\pi 1300t) + A_4 \sin(2\pi 1750t) + n(t)$, onde o ruído $n(t)$ é modulado no tempo por um envelope gaussiano.

3.






Para realizar a segmentação da forma de onda em sons vozeados (V), sons não-vozeados/surdos (N) e silêncio (S), usaremos os seguintes parâmetros:

- **Energia de Curta Duração (E):** Representa a potência do sinal em um quadro. Alta para sons vozeados, baixa para silêncio.

$$E[k] = \frac{1}{N} \sum_{n=0}^{N-1} s^2[n]$$



(a) Figuras Exercício 1



- **Magnitude Média de Curta Duração (MA):** Uma alternativa mais simples à energia, menos sensível a grandes variações de amplitude.

$$MA[k] = \frac{1}{N} \sum_{n=0}^{N-1} |s[n]|$$

- **Taxa de Cruzamento por Zero de Curta Duração (ZCR):** A taxa na qual o sinal muda de sinal. Alta para sons não vozeados (fricativos), baixa para sons vozeados.

$$ZCR[k] = \frac{1}{2N} \sum_{n=1}^{N-1} |\text{sgn}(x[n]) - \text{sgn}(x[n-1])|$$

no qual K é o número de segmentos e N é o número de amostras de cada segmento.

Portanto, de forma resumida:

- Sons Vozeados (ex: vogais): Apresentam alta energia e baixa ZCR, devido à sua natureza periódica.
- Sons Não Vozeados (ex: fricativas como /s/, /f/): Apresentam baixa energia e alta ZCR, devido à sua natureza aperiódica e ruidosa.
- Silêncio: Apresenta energia muito baixa. A ZCR pode ser alta devido ao ruído de fundo, mas a energia é o indicador principal.

Podemos considerar os segmentos com energia abaixo 1% da máxima como silêncio, e em caso contrário, se possuir ZCR acima de 0.1, tem-se som não vozeado e abaixo disso (ZCR baixo e energia alta), tem-se vozeado. Essas métricas são encontradas na literatura.

Observação: *todos códigos estão presentes no arquivo em anexo notebook formato .ipynb.*







Figure 2: Exercício 3) Oscilograma com segmentos





A “olho nu”, podemos identificar as partes com alta energia e baixo ZCR (regiões em vermelho), baixa energia nas regiões em amarelo e as que aparesentam os sons não-vozeados/surdos ou ruídos em verde.




Figure 3: Figura a “olho nu”

4.

Observação: todos códigos estão presentes no arquivo em anexo notebook formato .ipynb.

a)

Comprimento do quadro (em amostras): 64

Salto (em amostras): 32

Forma da matriz de quadros (comprimento_quadro, num_quadros): (64, 183)




Figure 4: Exercício 4.a

b)

Quantidade de quadros: 183





Figure 5: Exercício 4.b



c)




Figure 6: Exercício 4.c

d)




Figure 7: Exercício 4.d

Portanto, percebe-se que a frequência fundamental F0 calculada no método de SIFT tende a reduzir a influência dos formantes, enquanto na autocorrelação direta, os formantes do trato vocal influenciam fortemente os picos da função.